ЦЕНТР НЕПРЕРЫВНОГО ОБРАЗОВАНИЯ
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК

# Анализ факторов ценообразования и построение предиктивной модели для прогноза стоимости автомобилей с пробегом

**Юн Владислав Александрович**

# Постановка задачи

## ПРОБЛЕМА

1. **Много факторов**
2. **Субъективная оценка**
3. **Низкая воспроизводимость**

Цена автомобиля зависит от совокупности характеристик.

## ЦЕЛЬ

Построить модель прогнозирования стоимости автомобилей с пробегом, определить основные факторы ценообразования и реализовать её практическое применение

**Результат: модель + интерпретация + прикладной интерфейс**

## ЗАДАЧИ

**01** **Собрать и подготовить данные**

парсинг → очистка → признаки

**02** **Исследовать факторы цены**

EDA → зависимости → выводы

**03** **Построить и сравнить модели**

baseline → CatBoost → Optuna

**04** **Интерпретировать и применить**

SHAP → анализ ошибок → dashboard

**Логика работы: от сбора реальных объявлений — к объяснимой модели и её практическому использованию.**

# Сбор данных и выборка

01 • PARSE

| 4 006 | 39 | 175 | 17 |
|---|---|---|---|
| объявлений | брендов | моделей | исходных колонок |

## Как собирались данные

**Парсинг объявлений Drom.ru**

**Drom.ru** — источник

› **Selenium** — динамические страницы

› **HTML** — получение данных

› **BeautifulSoup / lxml** — разбор страниц

Дополнительно: requests • selenium-stealth • fake-useragent

**Результат → 4 006 объявлений и 17 исходных колонок**

## Что получено после сбора

| | |
|---|---|
| **Источник** | Drom.ru — объявления автомобилей с пробегом |
| **Цена** | целевая переменная — цена объявления |
| **Формат** | CSV с исходными характеристиками |
| **Срез** | данные отражают рынок на момент парсинга |

**Цена предложения ≠ цена сделки**

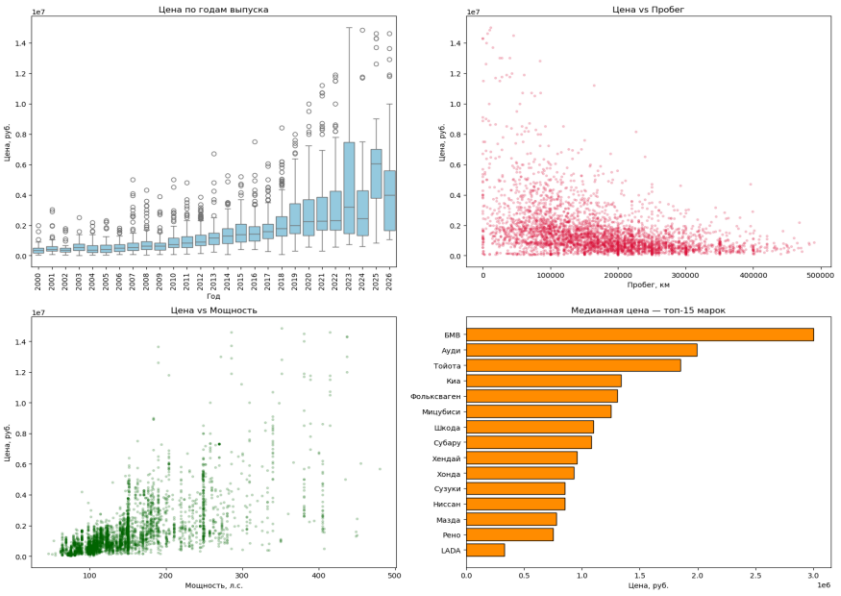
**После EDA и feature engineering: 21 колонка = 20 входных признаков + 1 целевая переменная «цена»**

# Разведочный анализ данных (EDA)



## Распределение цены

Правосторонняя асимметрия



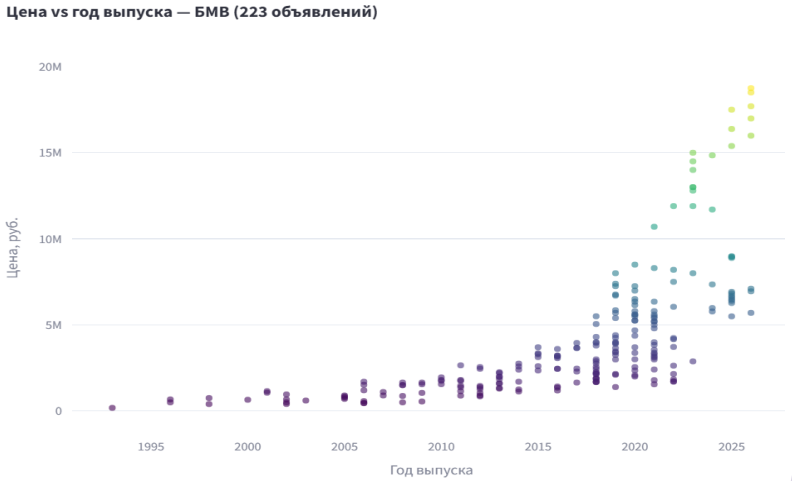

**Медиана 1,11 млн ₽**

**Среднее 1,75 млн ₽**

## Связи цены с характеристиками

Пример: год выпуска × цена

**Зависимость цены от года выпуска**




| Мощность | Год | Объём | Пробег |
|---|---|---|---|
| +0,67 | +0,52 | +0,43 | −0,40 |

**Вывод: цена зависит от характеристик автомобиля, но зависимости имеют нелинейный характер.**

# Подготовка данных

**4 006**
объявлений
→
**Очистка**
данных
→
**Пропуски**
и аномалии
→
**Признаки**
feature engineering
→
**21**
колонка

**ВХОДНЫЕ ПРИЗНАКИ**

**20** категориальные + числовые

**ЦЕЛЕВАЯ ПЕРЕМЕННАЯ**

**цена** 1 колонка

После подготовки данные разделены на обучающую и тестовую части.

# Построение модели прогнозирования

**20 признаков** → **CatBoost** → **Baseline** → **Optuna** → **Итоговая модель**

### Почему CatBoost?

- Нативная работа с категориальными признаками.
- Нелинейные зависимости.
- Взаимодействия между признаками.
- 10 категориальных колонок, включая модель (175 значений).

### Подбор гиперпараметров

**Optuna** **30 trials** **3-fold CV**

Сравнивались: наивный baseline, baseline CatBoost, CatBoost + Optuna и log-target.

# Результаты моделирования

03 • MODEL

**Финальная модель**

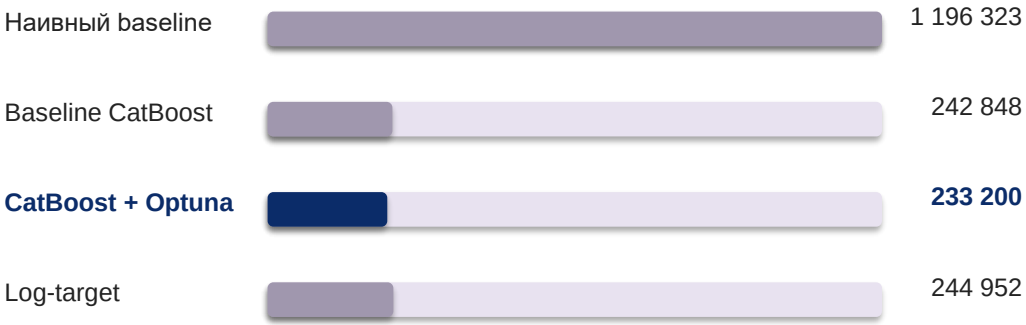
## CatBoost + Optuna

Лучший результат на тестовой выборке

| MAE | RMSE | $R^2$ |
|---|---|---|
| **233 тыс. ₽** | **420 тыс. ₽** | **0,964** |
| средняя абсолютная ошибка | чувствителен к крупным ошибкам | доля объяснённой вариации |

## Сравнение моделей по MAE

Меньше — лучше




## Что показало сравнение

**01** **CatBoost намного лучше**
наивного прогноза по медиане.

**02** **Optuna дала снижение MAE на 4%**
по MAE относительно baseline CatBoost.

**03** **Log-target хуже**
по MAE и RMSE, чем финальная модель.

**Тестовая выборка использована только для финальной оценки; выбор модели и early stopping — без доступа к test.**



факультет компьютерных наук

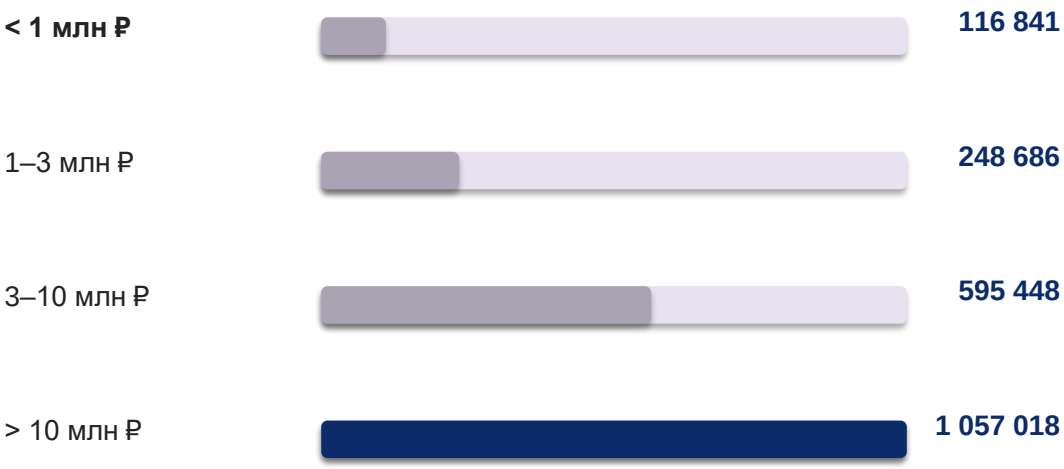
# Анализ ошибок по ценовым сегментам

04 • ERROR

## MAE по ценовым сегментам

MAE — средняя абсолютная ошибка прогноза

Меньше — лучше




## Что это означает

**01 Массовый сегмент**

до 1 млн ₽: MAE 116,8 тыс. ₽

**02 Средний сегмент**

1–3 млн ₽: MAE 248,7 тыс. ₽

**03 Дорогие авто**

3–10 млн ₽: MAE 595,4 тыс. ₽

**04 Премиум**

свыше 10 млн ₽: MAE 1,06 млн ₽

**Абсолютная ошибка растёт вместе с ценовым сегментом.**

# Интерпретация модели: SHAP



## Что модель считает важным?

Рейтинг по средней абсолютной величине SHAP-вклада




**Здесь важен порядок признаков, а не абсолютная денежная величина.**

## Что добавляет SHAP?

**01 Объясняет модель**
а не просто данные

**02 Показывает вклад**
каждого признака в прогноз

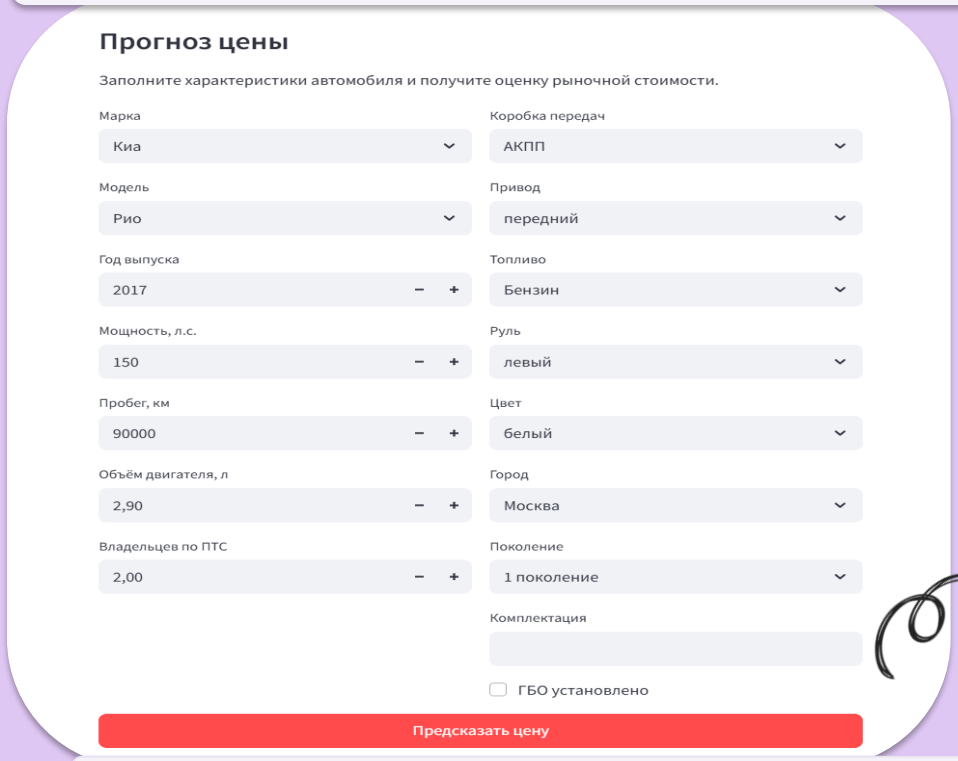
**03 Работает с объектом**
можно разобрать отдельный автомобиль

## Как интерпретировать вклад?

| | |
|---|---|
| **Год** | **положительный вклад** — более новый автомобиль → выше прогноз |
| **Мощность** | **положительный вклад** — большая мощность → выше прогноз |
| **Пробег** | **отрицательный вклад** — больший пробег → ниже прогноз |

# Практическое применение модели

Интерактивный dashboard позволяет исследовать рынок и получить индивидуальную оценку стоимости автомобиля.




## Что позволяет dashboard?

**01 Исследовать рынок**
Фильтрация объявлений и интерактивная аналитика

**02 Задать характеристики**
Основные параметры автомобиля вводятся через формы

**03 Получить прогноз**
Модель CatBoost рассчитывает стоимость автомобиля

**Прогноз: 1 959 506 ₽** MAE ≈ 233 000 ₽

Примечание: поле «Комплектация» оставлено пустым — прогноз может быть рассчитан при неполном наборе данных.

# Выводы, ограничения и развитие

## Ограничения

01 **Источник данных**
Цена объявления Drom.ru — это цена предложения, а не цена фактической сделки.

02 **Премиум-сегмент**
Для автомобилей дороже 10 млн ₽ абсолютная ошибка существенно выше.

03 **Редкие автомобили**
Для незнакомых марок и редких конфигураций прогноз менее надёжен.

04 **Актуальность**
Датасет — срез рынка; без обновления модель постепенно устаревает.

## Что показала работа

01 **Цена формируется совокупностью характеристик**
Наиболее заметны год, мощность, объём двигателя и пробег.

02 **Модель существенно лучше простого baseline**
CatBoost даёт большой выигрыш относительно прогноза по медиане.

03 **Ошибка зависит от ценового сегмента**
Абсолютная ошибка растёт для дорогих автомобилей.

04 **Модель можно интерпретировать**
SHAP показывает вклад признаков и помогает объяснять прогноз.

05 **Результат доведён до применения**
Модель подключена к функции прогноза и интерактивному dashboard.

## Дальнейшее развитие

01 **Расширить данные**
Больше объявлений, регионов, марок и временных периодов.

02 **Премиум-модель**
Отдельная модель или расширенная выборка для дорогих автомобилей.

03 **Развить дашборд**
Карта цен по регионам, сравнение марок, экспорт отчётов.

04 **Контроль качества**
Мониторинг качества прогнозов и периодическое переобучение.

**Область применения: ориентир для оценки стоимости в пределах распределения, представленного в обучающей выборке.**