ЦЕНТР НЕПРЕРЫВНОГО ОБРАЗОВАНИЯ
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК

Анализ факторов ценообразования и построение предиктивной модели для прогноза стоимости автомобилей с пробегом

Юн Владислав Александрович

Постановка задачи

ПРОБЛЕМА

1. **Много факторов**
2. **Субъективная оценка**
3. **Низкая воспроизводимость**

Цена автомобиля зависит от совокупности характеристик.

ЦЕЛЬ

Построить модель прогнозирования стоимости автомобилей с пробегом, определить основные факторы ценообразования и реализовать её практическое применение

Результат: модель + интерпретация + прикладной интерфейс

ЗАДАЧИ

01 **Собрать и подготовить данные**

парсинг → очистка → признаки

02 **Исследовать факторы цены**

EDA → зависимости → выводы

03 **Построить и сравнить модели**

baseline → CatBoost → Optuna

04 **Интерпретировать и применить**

SHAP → анализ ошибок → dashboard

Логика работы: от сбора реальных объявлений — к объяснимой модели и её практическому использованию.

Сбор данных и выборка

01 • PARSE

4 006	39	175	17
объявлений	брендов	моделей	исходных колонок

Как собирались данные

Парсинг объявлений Drom.ru

Drom.ru — источник

› **Selenium** — динамические страницы

› **HTML** — получение данных

› **BeautifulSoup / lxml** — разбор страниц

Дополнительно: requests • selenium-stealth • fake-useragent

Результат → 4 006 объявлений и 17 исходных колонок

Что получено после сбора

Источник	Drom.ru — объявления автомобилей с пробегом
Цена	целевая переменная — цена объявления
Формат	CSV с исходными характеристиками
Срез	данные отражают рынок на момент парсинга

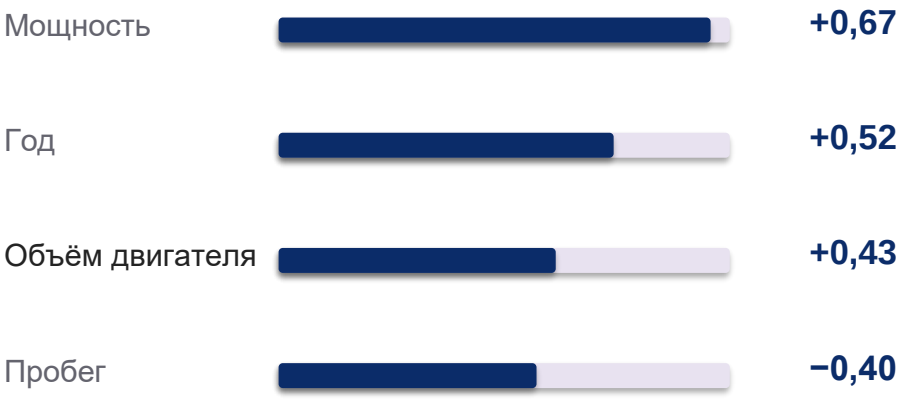
Цена предложения ≠ цена сделки

После EDA и feature engineering: 21 колонка = 20 входных признаков + 1 целевая переменная «цена»

Разведочный анализ данных (EDA)

Основные связи с ценой

Коэффициент Пирсона



Наиболее заметные связи: мощность, год, объём и пробег.

Что показал EDA

01 Распределение цены правосторонне скошено

02 Зависимость от цены характеристик имеет сложный характер

03 Выбросы проверены это реальные автомобили, а не ошибки данных

Вывод: наблюдаются выраженные зависимости между характеристиками и ценой

Подготовка данных

4 006
объявлений
→
Очистка
данных
→
Пропуски
и аномалии
→
Признаки
feature engineering
→
21
колонка

ВХОДНЫЕ ПРИЗНАКИ

20 категориальные + числовые

ЦЕЛЕВАЯ ПЕРЕМЕННАЯ

цена 1 колонка

После подготовки данные разделены на обучающую и тестовую части.

Построение модели прогнозирования

20 признаков → **CatBoost** → **Baseline** → **Optuna** → **Итоговая модель**

Почему CatBoost?

- Нативная работа с категориальными признаками.
- Нелинейные зависимости.
- Взаимодействия между признаками.
- 10 категориальных колонок, включая модель (175 значений).

Подбор гиперпараметров

Optuna **30 trials** **3-fold CV**

Сравнивались: наивный baseline, baseline CatBoost, CatBoost + Optuna и log-target.

Результаты моделирования

03 • MODEL

Финальная модель

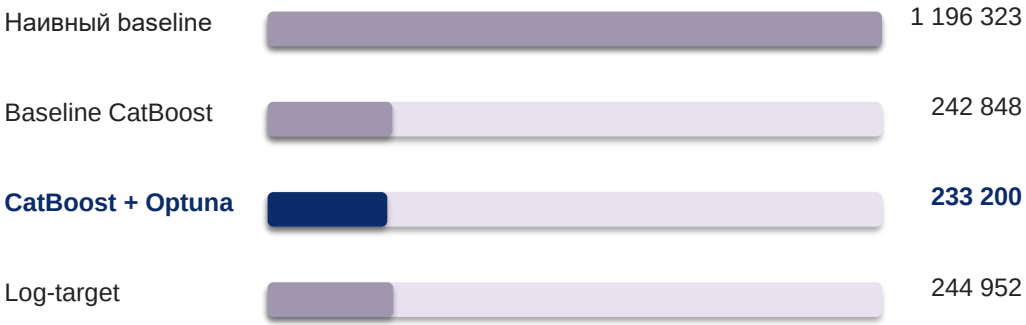
CatBoost + Optuna

Лучший результат на тестовой выборке

MAE	RMSE	R^2
233 тыс. ₽	**420 тыс. ₽**	**0,964**
средняя абсолютная ошибка	чувствителен к крупным ошибкам	доля объяснённой вариации

Сравнение моделей по MAE

Меньше — лучше



Что показало сравнение

01 **CatBoost намного лучше**
наивного прогноза по медиане.

02 **Optuna дала снижение MAE на 4%**
по MAE относительно baseline CatBoost.

03 **Log-target хуже**
по MAE и RMSE, чем финальная модель.

Тестовая выборка использована только для финальной оценки; выбор модели и early stopping — без доступа к test.

факультет компьютерных наук

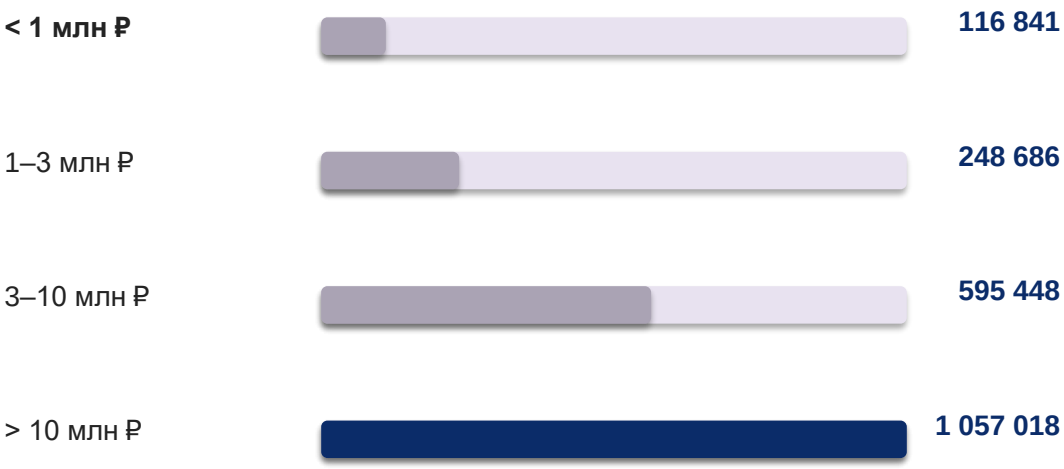
Анализ ошибок по ценовым сегментам

04 • ERROR

MAE по ценовым сегментам

MAE — средняя абсолютная ошибка прогноза

Меньше — лучше



Что это означает

01 Массовый сегмент

до 1 млн ₽: MAE 116,8 тыс. ₽

02 Средний сегмент

1–3 млн ₽: MAE 248,7 тыс. ₽

03 Дорогие авто

3–10 млн ₽: MAE 595,4 тыс. ₽

04 Премиум

свыше 10 млн ₽: MAE 1,06 млн ₽

Абсолютная ошибка растёт вместе с ценовым сегментом.

Интерпретация модели: SHAP

Что модель считает важным?

Рейтинг по средней абсолютной величине SHAP-вклада



Здесь важен порядок признаков, а не абсолютная денежная величина.

Что добавляет SHAP?

01 Объясняет модель
а не просто данные

02 Показывает вклад
каждого признака в прогноз

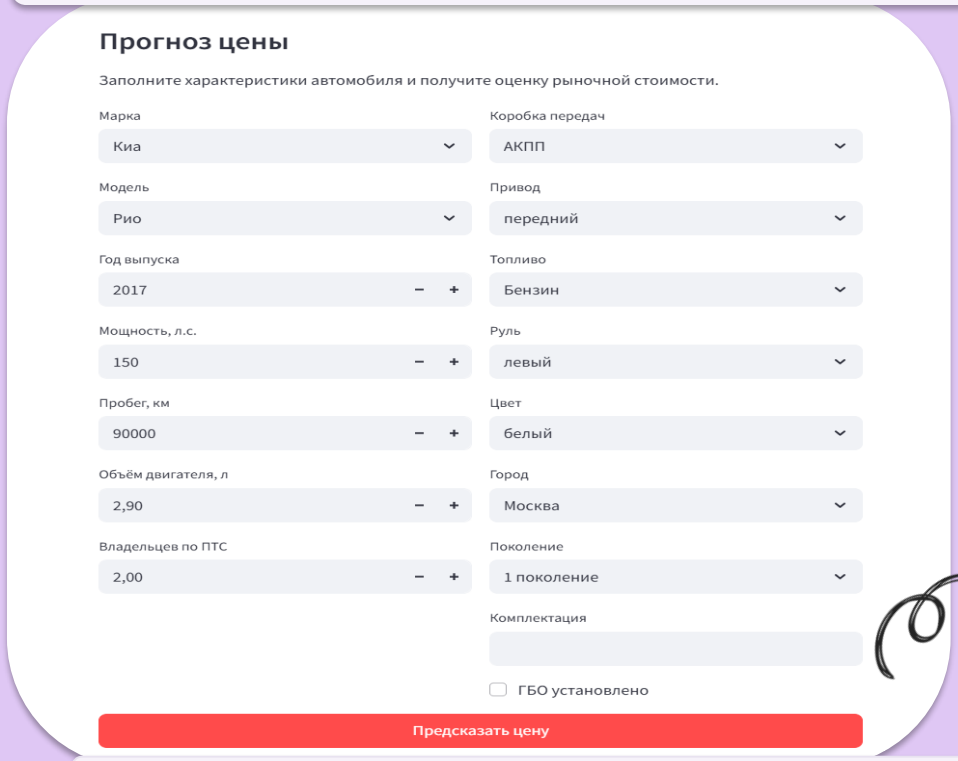
03 Работает с объектом
можно разобрать отдельный автомобиль

Как интерпретировать вклад?

Год	**положительный вклад** — более новый автомобиль → выше прогноз
Мощность	**положительный вклад** — большая мощность → выше прогноз
Пробег	**отрицательный вклад** — больший пробег → ниже прогноз

Практическое применение модели

Интерактивный dashboard позволяет исследовать рынок и получить индивидуальную оценку стоимости автомобиля.



Что позволяет dashboard?

01 Исследовать рынок
Фильтрация объявлений и интерактивная аналитика

02 Задать характеристики
Основные параметры автомобиля вводятся через формы

03 Получить прогноз
Модель CatBoost рассчитывает стоимость автомобиля

Прогноз: 1 959 506 ₽ MAE ≈ 233 000 ₽

Примечание: поле «Комплектация» оставлено пустым — прогноз может быть рассчитан при неполном наборе данных.

Выводы, ограничения и развитие

Ограничения

01 **Источник данных**
Цена объявления Drom.ru — это цена предложения, а не цена фактической сделки.

02 **Премиум-сегмент**
Для автомобилей дороже 10 млн ₽ абсолютная ошибка существенно выше.

03 **Редкие автомобили**
Для незнакомых марок и редких конфигураций прогноз менее надёжен.

04 **Актуальность**
Датасет — срез рынка; без обновления модель постепенно устаревает.

Что показала работа

01 **Цена формируется совокупностью характеристик**
Наиболее заметны год, мощность, объём двигателя и пробег.

02 **Модель существенно лучше простого baseline**
CatBoost даёт большой выигрыш относительно прогноза по медиане.

03 **Ошибка зависит от ценового сегмента**
Абсолютная ошибка растёт для дорогих автомобилей.

04 **Модель можно интерпретировать**
SHAP показывает вклад признаков и помогает объяснять прогноз.

05 **Результат доведён до применения**
Модель подключена к функции прогноза и интерактивному dashboard.

Дальнейшее развитие

01 **Расширить данные**
Больше объявлений, регионов, марок и временных периодов.

02 **Премиум-модель**
Отдельная модель или расширенная выборка для дорогих автомобилей.

03 **Развить дашборд**
Карта цен по регионам, сравнение марок, экспорт отчётов.

04 **Контроль качества**
Мониторинг качества прогнозов и периодическое переобучение.

Область применения: ориентир для оценки стоимости в пределах распределения, представленного в обучающей выборке.